

中原大學
資訊工程學系
碩士學位論文

基於區塊循環矩陣之遞迴神經網路加速器
系統架構探索與分析

System Architecture Exploration and Analysis for Recurrent Neural Networks with Block-
Circulant Matrices

指導教授：鄭維凱

研究生：朱芷瑩

中華民國 114 年 7 月

摘要

循環神經網路 (Recurrent Neural Network, RNN) 在處理序列相關資料有重要的表現，特別是在語言辨識、語言模型、機器翻譯以及時間序列預測方面。隨著深度學習模型的複雜度不斷增加，在計算資源需求和模型參數設定方面都有極大的壓力，因此，區塊循環遞迴神經網路利用區塊循環矩陣結構於神經網路中的權重矩陣，通過此結構化的權重設計顯著減少模型的參數量和計算複雜度，但由於不同的參數調整對整體的效能皆有不同的影響。

本研究提出一種基於區塊循環遞迴神經網路的自動超參數搜尋框架。此框架結合量子行為粒子群演算法在超參數空間中自動搜尋最適組合，透過機率分布函數其能夠搜尋全域最佳解，並採用 MAPE(平均絕對百分比誤差)評估值做模型適配度指標。

我們的方法既能顯著的縮短訓練時間，亦能保證不會損失模型的精度太多的前提下，有效提升模型整體效能與穩定性，展現出優於傳統優化策略之潛力。

Abstract

Recurrent Neural Network (RNN) has important performance in processing sequence-related data, especially in language recognition, language modeling, machine translation, and time series prediction. As the complexity of deep learning models continues to increase, there is great pressure on computing resource requirements and model parameter settings. Therefore, the block recurrent neural network uses the block recurrent matrix structure in the weight matrix of the neural network. This structured weight design significantly reduces the number of model parameters and computational complexity, but different parameter adjustments have different effects on the overall performance.

This study proposes an automatic hyperparameter search framework based on block recurrent neural networks. This framework combines the quantum-behaved particle swarm algorithm to automatically search for the best combination in the hyperparameter space. Through the probability distribution function, it can search for the best solution in the entire domain, and use the MAPE (mean absolute percentage error) evaluation value as the model fitness indicator.

Our method can significantly shorten training time while ensuring that model's accuracy does not suffer significantly, effectively improving overall model performance and stability, and demonstrating the potential to outperform traditional optimization strategies.

目錄

摘要	i
Abstract	ii
目錄	iii
圖目錄	iv
表目錄	v
第 1 章、緒論	1
第 2 章、背景研究	3
2-1 區塊循環遞迴神經網路	3
2-2 粒子群優化演算法(Particle Swarm Optimization Algorithm, PSO).....	4
2-3 量子行為粒子群演算法(Quantum-behaved Particle Swarm Optimization, QPSO)演算法	8
第 3 章、研究方法	11
3-1 研究動機與問題闡述:	11
3-2 Block Circulant LSTM/GRU	13
3-3 QPSO 演算法.....	15
3-4 雙向 BlockCirculantLSTM / BlockCirculantGRU	19
3-5 評估指標.....	20
第 4 章、實驗結果	22
4-1 實驗配置.....	22
4-2-1 南京市共享單車資料集實驗結果	23
4-2-2 電力變壓器資料集實驗結果.....	27
第 5 章、結論	31
參考文獻	32

圖目錄

圖 1 為 PSO 演算法之流程	5
圖 2 區塊循環遞迴神經網路結構圖	13
圖 3 為整體 QPSO-Block circulant RNN 運作流程	16
圖 4 雙向循環遞迴神經網路.....	19
圖 5 PSO、QPSO 演算法之預測結果綜合整理.....	26
圖 6 PSO 及 QPSO 演算法針對電力變壓器資料集之預測結果綜合比較	29



中原大學

表目錄

表格一為 PSO 及 QPSO 的綜合比較.....	10
表格二 QPSO 依據其參數範圍搜尋其最優解.....	22
表格三 PSO 演算法之預測結果.....	23
表格四 QPSO 演算法之預測結果.....	24
表格五 PSO 演算法針對電力變壓器資料集之預測結果.....	27
表格六 QPSO 演算法針對電力變壓器資料集之預測結果.....	28



中原大學

第1章、緒論

隨著深度學習技術的快速發展，循環神經網路（Recurrent Neural Network, RNN）在處理序列相關資料有重要的表現，特別是在語言辨識、語言模型、機器翻譯以及時間序列預測方面。其中，應用最廣泛、性能最高的主要 RNN 類型是長短期記憶單元（Long Short-Term Memory, LSTM）和門控循環單元（Gated Recurrent Unit, GRU）這兩種 RNN 變體，主要透過引入記憶單元和門控機制，成功解決傳統 RNN 在訓練過程中常見的梯度消失與梯度爆炸等問題，大幅提升整體模型的穩定性和性能表現。

然而，隨著深度學習模型的複雜度不斷增加，傳統的 RNN 及其他變體在計算資源需求和模型參數設定方面的挑戰也日益增多。為了應對這些挑戰，先前的研究提出一種基於區塊循環神經網路（Block Circulant Neural Network, BCNN）[1]的創新概念，該方法利用區塊循環矩陣結構於神經網路中的權重矩陣，特別是在遞迴神經網路（Recurrent Neural Network, RNN）架構中進行整合，形成所謂的區塊循環矩陣遞迴神經網路（Block Circulant Recurrent Neural Network, BCRNN）。此方法是利用矩陣的循環結構特性，通過結構化的權重設計顯著減少模型的參數量和計算複雜度，同時保留 RNN 在捕捉時間序列長期依賴關係方面的能力。這種方法不僅可降低模型的儲存需求和計算成本，還在保持預測精度的前提下實現了更高效的訓練和推理過程。

區塊循環矩陣的遞迴神經網路具有模型壓縮與加速等多項優點，尤其適合應用於硬體資源受限的環境。然而，不同的超參數設定對其效能表現有不同的影響，例如區塊大小、隱藏層維度、批次大小等。這些超參數的不同組合直接影響模型的計算效率、收斂速度以及最終的預測準確率。在傳統上，研究者往往依靠人工經驗搜尋進行參數調整，但此類方法不僅耗時，亦難保證能搜尋得全域最佳解。

為了解決上述問題，本研究提出一種基於區塊循環遞迴神經網路的自動超參數搜尋框架。此框架結合量子行為粒子群演算法在超參數空間中自動搜尋最適組合，從而提升模型在預測準確率與運算效率方面的整體表現。



中原大學

第2章、背景研究

2-1 區塊循環遞迴神經網路

區塊循環遞迴神經網路(Block-Circulant Recurrent Neural Network, BC-RNN) [1]是一種旨在壓縮模型參數、加速計算的神經網路架構，特別是針對像長短期記憶網路(Long Short-Term Memory, LSTM)或門控循環單元(Gated Recurrent Unit, GRU)這類循環神經網路(Recurrent Neural Network, RNN)進行優化。其主要的核心概念在於將原本大型的權重矩陣轉為由區塊循環矩陣(Block-Circulant Matrices)組成的結構，就是將一個大的矩陣拆解為若干小的方形子矩陣(稱為區塊)，並要求這些區塊內部的結構為循環矩陣。所謂循環矩陣，是指每一列皆為上一列向右循環平移的結果，例如：

$$\begin{bmatrix} a & b & c \\ c & a & b \\ b & c & a \end{bmatrix}$$

如此一來，只需儲存每個循環矩陣的第一列或第一欄，就能還原整個矩陣結構，進而大幅減少需要儲存的參數量。

近年來，有許多針對區塊循環遞迴神經網路的研究，例如：研究[2]提出一種結合區塊循環壓縮技術與以 ReRAM 為基礎的記憶體內運算(Processing-In-Memory, PIM)架構。此研究的系統採用脈動資料流與 ReRAM 交叉開關陣列，能有效支援區塊循環 RNN 的運算特性。同時，此研究將全連接層中的矩陣乘法運算轉換為一系列傅立葉轉換(FFT)與逐點乘法操作，進一步降低模型的空間與時間

複雜度。

另外，研究[12][13][14]也證明了區塊循環遞迴神經網路與傳統的 LSTM 相比，區塊循環遞迴神經網路的權重矩陣架構能有效的降低模型的儲存空間和整體的運算成本。這些特點可以有效解決在邊緣運算裝置上的種種限制。因此本研究提出一種基於區塊循環遞迴神經網路的混合式架構，以改善傳統 LSTM 在邊緣運算中的限制。

2-2 粒子群優化演算法(Particle Swarm Optimization Algorithm, PSO)

粒子群優化演算法(Particle Swarm Optimization Algorithm, PSO)是一種源於觀察群體行為的最佳化演算法，由 J. Kennedy 和 R. C. Eberhart 兩位學者於 1995 年提出[3]。該演算法以模擬鳥群或魚群等自然群體的行為，透過粒子間的資訊交流與合作，進而達成對全域最優解的有效探索。

在 PSO 中，每個粒子代表一個最佳化問題的解，它透過適應值函數計算其適配度，並根據自身經驗 (pbest) 及群體最佳經驗 (gbest) 動態調整速度與位置。透過這樣的方式，粒子能在迭代過程中逐漸收斂到最優解。由於 PSO 屬於隨機搜尋演算法，因此特別適合解決高維度、非線性與多峰值等複雜的問題。

Algorithm PSO

```
For each of the  $N$  particles:
    Initialize velocity  $V_i$  and position  $x_i$ 
    Evaluate particle  $i$  and set position  $p_i(0) = x_i(0)$ 
end for
initialize the global best as  $g = \min(p_i(0))$ 
while not stop
    for  $i = 1$  to  $N$ 
        Update the particle velocity and particle position
        Evaluate particle  $i$ 
        If  $\text{fit}(X_i) < \text{fit}(p_i(0))$ 
             $p_i(0) = x_i(0)$ ;
        if  $\text{fit}(p_i(0)) < \text{fit}(g)$ 
             $g = p_i(0)$ ;
        end for
    end while
```

圖 1 為 PSO 演算法之流程

PSO 演算法主要分為五個重要步驟，其說明如下所述：

1. 對於每一個粒子 $i = 1 \sim N$ ，先進行初始化，包括隨機化初始位置 $x_i(0)$ 、設定個體最佳位置 $p_i(0) = x_i(0)$ 、計算適應度 $f(\cdot)$ ，選出全域最佳位置 g 。

2. 接著，每個粒子進行速度更新，公式如下：

$$v_i(t+1) = w \cdot v_i(t) + c_1 \cdot r_1 \cdot (p_i - x_i(t)) + c_2 \cdot r_2 \cdot (g - x_i(t))$$

其中， w 為慣性權重，用來控制粒子對前一速度的依賴程度； c_1 、 c_2 為加速係數，代表粒子的自我學習與社會學習能力；而 r_1 、 r_2 則是隨機因子，介於 $1 \sim 0$ 之間，用以增加搜尋的多樣性。

3. 粒子根據更新後的速度移動到新位置：

$$x_i(t+1) = x_i(t) + v_i(t+1)$$

此公式說明粒子根據當前速度向量移動，尋找新的位置。

4. 對新的位置 $x_i(t+1)$ ，計算目標函數 $f(x_i(t+1))$ ，若其表現優於原本的個體最佳，則更新 $pbest$ ；若表現優於目前全域最佳，則更新 $gbest$ 。
5. 不斷重複上述過程，直到達到設定的終止條件，如達到最大迭代次數或全域最佳解變動小於某容許範圍為止。

近年來，PSO 演算法也被廣泛應用於各類模型之參數搜尋與結構設計中。例如：研究[4]提出一種結合 LSTM 神經網路和粒子群優化 (PSO) 的深度學習神經網路，利用 PSO 演算法優化 LSTM 參數，並透過 NSE 值來調整超參數大小，使模型能夠適應不同的情況，從而提高學習資料序列特徵的能力，增加預測的精確度及效率。研究[5]提出一種深度學習模型 CNN-LSTM-AP，該模型結合 CNN 的局部特徵提取能力和 LSTM 網路的時間序列預測能力，以提高馬達故障的預測精度。同時採用粒子群優化 (PSO) 演算法進行超參數最佳化，此混合式架構不僅能有效減少人工調參的時間與成本，也克服了傳統單一神經網路的局限性，並提高了模型整體的預測精度。彰顯了此架構在處理複雜預測任務方面的強大能力和潛在的應用前景。

此外，為了提升其搜尋能力與避免陷入局部極值的缺點，PSO 演算法也衍生出多種改良版本。較具代表性的變形包括：

- 量子行為粒子群演算法 (Quantum-behaved PSO, QPSO) [6]：
引入量子力學原理，以機率分佈方式重新定義粒子位置更新方式，增強全域搜尋能力。

- 多目標粒子群演算法 (MOPSO) [7]：針對同時具有多種指標的問題進行解集合搜尋，適用於多目標動態調度最佳化問題。
- 混合式演算法 (Hybrid PSO) [8]：與其他演算法如遺傳演算法 (GA) [8]、模擬退火法 (SA) [9]等結合，以取得更好的解。

目前，PSO 也被廣泛應用於神經網路架構搜尋 (Neural Architecture Search, NAS) [15][16]、強化學習中的策略搜尋、特徵選擇 (Feature Selection) 與自動化機器學習 (AutoML) [17]等現代人工智慧研究中，證明其適應力與彈性。



中原大學

2-3 量子行為粒子群演算法(Quantum-behaved Particle Swarm Optimization, QPSO)演算法

雖然粒子群最佳化 (PSO) 是一種廣泛應用的演算法，特別是在解決非線性優化問題上具有良好表現，但仍可能受限於收斂速度較慢或容易陷入區域最小值等問題。為了提升其全域搜尋能力與理論嚴謹性，學者提出了量子粒子群優化演算法 (Quantum-behaved Particle Swarm Optimization, QPSO) [6]，其核心思想是基於量子力學中粒子波動行為的假設，使粒子的更新機制不再依賴經典的速度與位置，而是以機率分佈方式進行全域搜尋。

與傳統 PSO 相比，QPSO 中每個粒子的下一個位置是根據局部吸引點 (local attractor) 與機率密度函數 (如指數分佈) 進行樣本抽樣決定。

QPSO 核心公式分為三個部分：

1. 全局平均最佳位置 (Mean Best, $mbest$)，即所有粒子的歷史最佳位置的平均值，其公式如下：

$$mbest = \left(\frac{1}{n}\right) * \sum p_i$$

其中 N 是粒子數量， p_i 是第 i 個粒子的個體最佳位置。

2. 粒子吸引點公式如下：

$$p_i = a \cdot pbest_i + (1-a) \cdot gbest, a(0,1)$$

其中， p_i 為是第 i 個粒子的個體最佳位置， a 是介於 0 和 1 之間的隨機數， $pbest_i$ 是粒子的個體最佳位置， $gbest$ 是全局最佳位置。

3. 粒子位置更新公式如下:

$$x_i(t+1) = p_i \pm \beta \cdot |mbest - x_i(t)| \cdot \ln\left(\frac{1}{u}\right), u(0,1)$$

其中， $x_i(t)$ 粒子 i 在第 t 次迭代的位置， p_i 為第 i 個粒子的個體最佳位置， $gbest$ 是全局平均最佳位置， β 是收縮膨脹係數，用以控制搜尋範圍。 u 是介於 0 和 1 之間的隨機數。 $\pm$ 符號是隨機選擇。

這種機率性的更新方式提升了模型跳脫區域最小值的能力。同時，縮放參數 β 可控制粒子的搜索範圍，並藉由調整收斂參數增加探索與利用的平衡。

在深度學習應用中，QPSO 亦用於 LSTM 模型的超參數優化，即形成 QPSO-LSTM 架構[10][18]。由於 QPSO 擁有更強的全域搜尋能力與較高的收斂效率，且在處理高維超參數空間時相較 PSO 更具優勢。而 QPSO-LSTM 同樣是依照初始化、模型建立、適應度評估與粒子更新等流程，其與 PSO-LSTM 的不同之處在於更新機制導入了量子行為模型，可以使粒子更新的位置不再受速度向量影響，故其更適合用於複雜時間序列的建模與預測。

根據研究[19][20]可知，在面對一些突然的峰值，QPSO 的表現能夠優於 PSO，在 PSO 中容易忽視這些峰值，以模糊的方式帶過，進而影響精度，然而 QPSO 在處理具有突發性波動或極端值的時間序列資料時有更為突出的表現。故本研究提出將此演算法結合區塊循環遞迴神經網路，使其能夠提升模型對時間序列中突變趨勢的感知能力，進一步強化預測準確率，並且透過此演算法找出全域最佳解以更加快速且有效率的方式尋找。

表格一為 PSO 及 QPSO 的綜合比較

特性	粒子群優化(PSO)	量子行為粒子群優化(QPSO)
基礎理論	基於經典牛頓力學	基於量子力學原理
搜索機制	粒子在空間中按照固定的軌跡移動	粒子遵循量子行為，可以出現在空間的任何位置
位置更新公式	依據速度更新公式	位置更新使用平均最佳位置（mbest）和隨機概率分佈
全局搜索能力	較弱，容易陷入局部最優	較強，具有更好的全局收斂性
計算複雜度	相對較低，計算簡單，適於一般優化問題	稍高，一般適合用於複雜時間序列的問題

中原大學

第3章、研究方法

3-1 研究動機與問題闡述:

遞迴神經網路 (Recurrent Neural Network, RNN) 目前已被廣泛應用於時間序列預測、語音識別與自然語言處理等領域。然而，傳統 RNN 的結構在模型複雜度與硬體資源需求上存在明顯限制，特別是在資源有限的環境中部署與應用。

研究[11]提出將區塊循環矩陣 (Block Circulant Matrix) 引入 RNN 結構中，透過將 RNN 權重結構化為區塊循環形式，發展出區塊循環遞迴神經網路，進而壓縮模型規模、減少計算量，並同時保留 RNN 對時序特徵的擷取能力。然而，區塊循環結構可提升效率，但其效能仍高度依賴超參數的選擇，如區塊大小、隱藏層維度、批次大小與模型類型等。這些參數若設定不當，可能導致模型準確率下降、收斂速度變慢，甚至造成不必要的計算資源浪費。然而，過往的研究多仰賴人工經驗進行超參數調整，不僅效率低落，亦容易陷入局部最適解，難以發揮模型的最大潛能。

研究[4]利用 PSO 演算法優化 LSTM 參數，並透過 NSE 值作為適應度函數，此方法藉由不斷更新粒子位置與速度，自動搜尋最佳超參數組合；相較之下，研究[10]提出 QPSO 以及 LSTM 的結合透過以群體平均最優解與個體吸引點為中心隨機抽樣進行全域探索，使粒子在全域空間中具備更高的探索能力，亦提升跳離局部最佳的能力。

因此，本研究旨在提出一種基於區塊循環遞迴神經網路與量子行為粒子群優化演算法結合的混合式架構，在整體模型架構設計上，主要分為兩個核心部分：區塊循環遞迴神經網路模型與超參數最佳化模組。前者用於處理時間序列資料捕捉序列資料中的動態特徵，同時透過區塊循環矩陣壓縮權重矩陣，減少模型參數量與計算負擔；後者則採用物理量子行為粒子群演算法，用於自動搜尋模型最佳參數配置。本研究期望此結構設計能夠在不犧牲準確率的期望下提升整體預測準確率與運算效率。



3-2 Block Circulant LSTM/GRU

區塊循環 LSTM 是一種將區塊循環矩陣應用於 LSTM 權重矩陣的結構。其核心組成部分與標準 LSTM 類似，包括記憶單元和三個主要的門控機制(輸入門、輸出門、遺忘門)，但權重矩陣被結構化為區塊循環形式，從而減少參數數量並加速計算。同樣地，區塊循環 GRU 的組成部分也與標準 GRU 相似，包含隱藏狀態及兩個門控機制(更新門及重置門)，其權重矩陣部分同樣採用區塊循環結構，進而有效降低參數量並提升計算效率。




圖 2 區塊循環遞迴神經網路結構圖

如圖 2 所示，未結構化的權重矩陣需儲存 18 個參數，但透過區塊大小為 2 的分割，可將整體儲存的參數量減少至 6 個參數。

首先，我們會先定義一個標準的 LSTMCell/GRUCell，並將其
中的權重矩陣轉換為區塊循環矩陣。若指定的區塊大小無法剛好整
除輸入維度(input_dim+hidden_dim)，則會使用 padding 的方式，將時
間步的輸入向量補齊至可整除的長度，避免在後續進行計算時出現
維度錯誤。

接者，將定義完成的 LSTMCell/GRUCell 放至 Keras 的 layer 之
中，形成一個深度學習模型的架構，透過 Sequential 模型串接多層
Block RNN 結構，並進行訓練與預測。



3-3 QPSO 演算法

因此，本研究結合量子粒子群優化算法（QPSO, Quantum Particle Swarm Optimization）來進行優化模型的超參數組合，其中的參數組合包括時間窗口大小，隱藏層維度、區塊大小、批次大小與模型類型等。每一粒子代表一組超參數設定，並根據模型在驗證資料上的預測表現（如均方誤差 RMSE 或平均絕對百分比誤差 MAPE）進行適配度評估。

在 QPSO 演算法中，其中極具核心的概念為 *pbest*（個人最佳位置）和 *gbest*（全局最佳位置）：

1. *pbest*：每個粒子在迭代過程中記錄自身歷史上最佳的超參數組合，即該粒子在驗證資料上獲得最佳適應度的位置。
2. *gbest*：整個粒子群在所有迭代中找到的最佳超參數組合，即全局最佳適應度的位置。

QPSO 演算法的搜索機制，是利用 *pbest* 和 *gbest* 引導粒子在超參數空間中移動，以尋找全局最優解，具體公式如下：

$$x_i(t+1) = p_i \pm \beta \cdot |mbest - x_i(t)| \cdot \ln\left(\frac{1}{u}\right), u(0,1)$$

$x_i(t)$ 粒子 i 在第 t 次迭代的位置， p_i 為是第 i 個粒子的個體最佳位置， $gbest$ 是全局平均最佳位置， β 是收縮膨脹係數，用以控制搜尋範圍。 u 是介於 0 和 1 之間的隨機數。 $\pm$ 符號是隨機選擇。

與傳統的 PSO 不同，QPSO 並不會透過速度向量來更新粒子的位置，而是透過一種帶有隨機性的量子機率模型來更新，使新的粒子得以跳出局部最小值區域，提升全域搜尋的能力。

隨著多次的迭代後，QPSO 會幫我們選出一組在驗證集上表現最好的超參數，我們就用這組參數來建立最終的 RNN 類型模型，用於測試或實際應用。

整體架構流程如圖 3 所示，包含以下六個步驟：




圖 3 為整體 QPSO-Block circulant RNN 運作流程

第一步：針對各資料集進行預處理。先將資料載入，接著使用 MinMaxScaler 進行特徵標準化，將所有特徵標準化至 [0,1] 區間，以避免各欄位量級差異影響模型訓練穩定性，最後再進行資料分割分為 80% 訓練集和 20% 測試集。

第二步：初始化一組粒子組合，其中的參數組合包括 6 個參數粒子：

- 時間窗口大小
- 第一層隱藏層層數
- 第二層隱藏層層數
- 批次大小
- 區塊大小
- 模型類型

並同時設定粒子組合的最大最小範圍。

第三步：初始化區塊循環遞迴神經網路，本研究中的區塊循環遞迴神經網路是由多層的 BlockCirculantLSTM cell / BlockCirculantGRU cell 所組合而成。其中 3 個參數至關重要，例如：

- 時間窗口大小，為決定模型考慮的歷史時間長度。
- 每層隱藏層的單元數，即為每層 LSTM/GRU 的單元數量。
- 區塊大小，是構成區塊循環矩陣之最小單元，其大小會決定整個區塊循環矩陣的壓縮程度。

第四步：利用 (MAPE 或 RMSE) 來評估適配度。

- MAPE (平均絕對百分比誤差) 為實際值和預測值間百分比誤差的絕對值，其計算公式為：

$$\sum_{i=1}^n (|y_i^{true} - y_i^{pred}| / y_i^{true}) / n。$$

其中， y^{true} 為實際值， y^{pred} 為預測值， n 為樣本數。

故 MAPE 的值越小，即表示此模型越精準。

- RMSE (均方誤差絕對值) 為預測值和實際值之間的平均偏差大小，其中的計算公式為：

$$\sqrt{\left[\left(\frac{1}{n}\right) * \sum_{i=1}^n (y_i^{true} - y_i^{pred})^2\right]}$$

其中， n 為樣本數， y_{true} 為真實值， y_{pred} 為預測值。故 MAPE 的值越小，即表示此模型越精準。

第五步：根據 QPSO 算法來更新粒子位置。首先計算所有粒子個體最佳位置的平均值 (m_{best})，然後為每個粒子確定局部吸引點 (p_i) 作為個體最佳位置與全局最佳位置的加權組合，接著，粒子位置會根據下方的計算公式進行更新。

$$x_i(t+1) = p_i \pm \beta \cdot |m_{best} - x_i(t)| \cdot \ln\left(\frac{1}{u}\right), u(0,1)$$

$x_i(t)$ 粒子 i 在第 t 次迭代的位置， p_i 為是第 i 個粒子的個體最佳位置， g_{best} 是全局平均最佳位置， β 是收縮膨脹係數，用以控制搜尋範圍。 u 是介於 0 和 1 之間的隨機數。 $\pm$ 符號是隨機選擇。

第六步：重複訓練與更新步驟，直到達到停止條件，例如達到最大迭代次數或最佳適應度收斂。

第七步：選擇最優參數組合，用來建立最終的區塊循環 RNN 模型，並進行測試或實際預測。

3-4 雙向 BlockCirculantLSTM / BlockCirculantGRU

最後，在模型測試階段，最終的區塊循環遞迴神經網路是由雙層雙向的 BlockCirculantLSTM / BlockCirculantGRU 建構而成的。

其中心概念為同時建立兩個 RNN 結構，一個以正向時間序列輸入（正向傳播），另一個則以反向時間序列輸入（反向傳播）。最終在每個時間點上，結合兩個方向的隱藏層狀態作為輸出，進而捕捉上下文中「過去」與「未來」的資訊，如圖 4 所示：




圖 4 雙向循環遞迴神經網路

此架構具有強大的上下文的理解能力，能同時考量過去和未來的資訊，特別適用於語言模型及時間序列預測等場景，有效提高預測的準確性與穩定性。

3-5 評估指標

為了全面評估模型表現，本研究會以準確率、MAE（平均絕對誤差）、 R^2 （決定係數）、MAPE（平均絕對百分比誤差）與RMSE（均方誤差絕對值）做最終模型預測結果之主要評估指標。

以下為四個模型評估指標的公式及特性：

1. MAE（Mean Absolute Error，平均絕對誤差）：

MAE 為預測值與實際值之間的平均絕對誤差，其計算公式為：

$$\frac{1}{n} \sum_{i=1}^n |y_i^{true} - y_i^{pred}|。$$

其中， n 為樣本數，故數值越小代表預測越精確。

2. R^2 （Coefficient of Determination，決定係數）：

R^2 是用來表示自變數因變數變異的比例，數值介於 0 到 1 之間，越接近 1 表示模型擬合效果越好。其計算公式如下：

$$1 - \left(\frac{SS_{res}}{SS_{tot}} \right)。$$

其中， SS_{res} 為殘差平方和，即表示不能解釋的部分，其公式為： $\sum (y_i - \hat{y}_i)^2$ 。

SS_{tot} 為總平方和，即表示欲解釋的總變異量，其公式為：

$$\sum (y_i - \bar{y})^2。$$

其中 y_i 為實際值， $\hat{y}_i$ 為平均觀察值，故

$$R^2 = 1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2。$$

3. MAPE (Mean Absolute Percentage Error, 平均絕對百分比誤差):

MAPE (平均絕對百分比誤差) 為實際值和預測值間百分比誤差的絕對值，其計算公式為：

$$\sum_{i=1}^n (|y_i^{true} - y_i^{pred}| / y_i^{true}) / n * 100\%。$$

故 MAPE 的值越小，即表示此模型越精準。

4. RMSE (Root Mean Square Error, 均方誤差絕對值):

RMSE 為預測值和實際值之間的平均偏差大小，其中的計算公

式為: $\sqrt{[(\frac{1}{n}) * \sum_{i=1}^n (y_i^{true} - y_i^{pred})^2]}。$

故 MAPE 的值越小，即表示此模型越精準。

我們的架構流程不僅結合結構壓縮的優點，同時運用 QPSO 的全域探索能力，有效提升訓練效率與模型效能。

第4章、實驗結果

4-1 實驗配置

為了驗證所提 QPSO-Block Circulant RNN 模型的預測效果，我們採用南京市共享單車使用資料集[10]以及電力變壓器資料集[21]進行模型的效能評估與預測。前者資料集是預測南京市在尖峰時段及離峰時段的各站點可用單車數量預估。資料集總筆數約為：648 筆，其中包含時間戳記、站點資訊與對應的單車數量紀錄等欄位；後者資料集主要是用以預測電力變壓器的安全油溫。資料集總筆數約為：69000 筆，其內容包括該點的日期、預測值「油溫」以及 6 種不同類型的外部電力負載特徵。本實驗會將實驗資料集以 8：2 的比例分為訓練集和測試集，並在最終實驗階段使用雙層雙向 RNN 結構模型進行最終實驗的預測與分析。

表格 二 QPSO 依據其參數範圍搜尋其最優解

超參數	參數範圍	最優解
時間窗口大小	[2,6]	4
第一層隱藏層	[256,512]	257
第二層隱藏層	[128,256]	128
批次大小	[3,20]	12
模型類型	[0,1] 0 為 LSTM,1 為 GRU	0
區塊大小	[8,64]	64

表格二為 QPSO 以及 PSO 演算法會依據設定之參數範圍在超參數空間中進行搜尋，並以平均絕對百分比誤差 (MAPE) 評估值做為適配度的指標進行評估與比較。表中右側欄位的最優解即為 QPSO-BLKLSTM 所預測的結果。

4-2-1 南京市共享單車資料集實驗結果

針對南京市共享單車資料集[10]，本研究以 PSO 及 QPSO 演算法進行超參數搜尋，並分別建立 LSTM、BLKLSTM、GRU 與 BLKGRU 等四種模型，所得預測結果如表格三、表格四所示。

表格三 PSO 演算法之預測結果

	PSO-BLKLSTM	PSO-BLKGRU	PSO-LSTM	PSO-GRU
推薦參數	[4, 256, 128, 11, 0, 64]	[4, 256, 128, 4, 1, 61]	[4, 256, 128, 11, 0, 64]	[4, 256, 128, 4, 1, 61]
Training time	146.1910 sec	426.4207 sec	746.8133 sec	532.2480 sec
Accuracy	82.48%	82.88%	86.7861%	83.55%
MAPE	17.52%	17.11%	14.21%	16.44%
RMSE	424.6902	338.8224	364.0910	399.2789
MAE	320.22	251.0827	259.2987	210.5003
R^2	0.5786	0.6936	0.6462	0.7778

表格三為 PSO 針對南京市共享單車使用資料集[10]所推薦之參數，可以觀察到在 PSO-LSTM 在準確率上有 86.78%，具有極佳的預測能力，但其訓練時間卻是四組資料中最長的，反觀 PSO-BLKGRU 在準確率上有 86.88%、 R^2 有 0.6936，且其各項評估指標皆為四組模型中最低，模型訓練時間也僅耗費 426.4270 秒，顯示這模型能夠兼顧模型效能的同時，亦保持模型的效率；PSO-GRU 的準確率為 83.55%， R^2 方面有 0.7778，唯獨在訓練時間上，需要耗時 532.24 秒；雖然 PSO-BLKLSTM 在其他的指標上說明其預測能力略遜一籌，但在時間上卻有極佳的表現。

表格 四 QPSO 演算法之預測結果

	QPSO-BLKLSTM	QPSO-BLKGRU	QPSO-LSTM	QPSO-GRU
推薦參數	[4, 257, 128, 12, 0, 64]	[3, 256, 128, 3, 1, 64]	[4, 257, 128, 12, 0, 64]	[3, 256, 128, 3, 1, 64]
Training time	130.2910 sec	448.3371 sec	512.0020sec	771.8886sec
Accuracy	84.51%	81.6638%	85.4%	84.0606%
MAPE	15.49%	18.3362%	15.1189%	15.9394%
RMSE	384.2299	480.1960	375.3413	400.0476
MAE	188.7756	361.8641	291.3963	300.1620
R^2	0.6060	0.3853	0.6240	0.5734

表格四為 QPSO 針對南京市共享單車使用資料集[10]所推薦之參數，首先，可以觀察到 QPSO-LSTM 在精度相關指標上表現最佳，其準確率達 85.4%，MAPE 與 RMSE 也分別為 15.12% 與 375.34，並擁有最高的 R^2 值 0.624，顯示其具備最強的預測能力與穩定性，但其訓練時間相對較長 512 秒。相較之下，QPSO-BLKLSTM 在效能上表現突出，訓練時間僅需 130 秒，遠低於其他模型，且 MAE 的 188.78 優於所有對照組，證明區塊循環結構能有效降低參數規模並維持合理精度。

在 GRU 架構下，QPSO-GRU 與 QPSO-BLKGRU 呈現明顯差異。QPSO-GRU 的準確率達 84.06%，優於 QPSO-BLKGRU 的 81.66%，MAPE 與 RMSE 也分別低於 BLKGRU，顯示傳統 GRU 在精度與誤差控制上具有優勢。而且，QPSO-GRU 的訓練時間高達 771.89 秒遠高於 QPSO-BLKGRU 的 448.34 秒，說明引入區塊循環結構確實能有效減少運算成本。整體而言，QPSO-GRU 具備較高的預測精度與穩定性，但代價是訓練時間過長；相對地，QPSO-BLKGRU 雖犧牲部分精度與擬合能力，但在效率上更具優勢，適合於對計算成本更為敏感的應用場景。

	PSO- BLKLSTM	PSO-LSTM	PSO- BLKGRU	PSO-GRU	QPSO- BLKLSTM	QPSO- LSTM	QPSO- BLKGRU	QPSO- GRU
推薦參數	[4, 256, 128, 11, 0, 64]	[4, 256, 128, 11, 0, 64]	[4, 256, 128, 4, 1, 61]	[4, 256, 128, 4, 1, 61]	[4, 257, 128, 12, 0, 64]	[4, 257, 128, 12, 0, 64]	[3, 256, 128, 3, 1, 64]	[3, 256, 128, 3, 1, 64]
Training time	146.1910 sec	746.8133 sec	426.4207 sec	532.2480 sec	130.2910 sec	512.0020 sec	448.3371 sec	771.8886 sec
Accuracy	82.48%	86.78%	82.88%	83.55%	84.51%	85.4%	81.6638%	84.06%
MAPE	17.52%	14.21%	17.11%	16.44%	15.49%	15.1189%	18.3362%	15.9394%
RMSE	424.6902	364.0910	338.8224	399.278	384.2299	375.3413	480.1960	400.0476
MAE	320.22	259.2987	251.0827	210.500	188.7756	291.3963	361.8641	300.1620
R^2	0.5786	0.6462	0.6936	0.7778	0.6060	0.6240	0.3853	0.5734

圖 5 PSO、QPSO 演算法之預測結果綜合整理

由圖 5 可以觀察出區塊循環遞迴神經網路結合 QPSO 演算法後，確實能有效提升模型效能與運算效率。在同演算法下比較，無論是採用 PSO 或 QPSO 的區塊循環遞迴神經網路，例如：PSO-BLKLSTM、QPSO-BLKGRU 等模型，在訓練時間與部分誤差指標上皆優於其對應的傳統架構，例如：PSO-LSTM、QPSO-GRU 等模型，皆顯示區塊循環的結構確實具備參數壓縮及加速效果，且不會明顯犧牲預測準確性。

4-2-2 電力變壓器資料集實驗結果

為了驗證模型效能，本研究針對電力變壓器資料集 [21]，以 PSO 及 QPSO 演算法進行超參數搜尋，並分別應用於 LSTM、BLKLSTM、GRU 與 BLKGRU 等四種模型，所得預測結果如表格五、表格六所示。

表格 五 PSO 演算法針對電力變壓器資料集之預測結果

	PSO- BLKLSTM	PSO-LSTM	PSO- BLKGRU	PSO-GRU
推薦參數	[6, 256, 128, 3, 0, 8]	[6, 256, 128, 3, 0, 8]	[5, 256, 128, 3, 1, 64]	[5, 256, 128, 3, 1, 64]
Training time	311.08 sec	569.44 sec	297.87 sec	506.45 sec
Accuracy	84.79%	85.55%	81.56%	82.08%
MAPE	15.21%	14.45%	18.44%	17.92%
RMSE	0.2193	0.0912	0.099	0.8058
MAE	0.0575	0.0686	0.7494	0.0559
R^2	0.9600	0.9485	0.9388	0.9598

由表格五可以觀察出 PSO-LSTM 在準確率達到 85.55%、MAPE 為 14.45% 及 RMSE 僅 0.0912 其整體表現最佳，但訓練時間最長需要 569.44 秒，效率相對不足；相較之下，PSO-BLKLSTM 將訓練時間縮短至 311.08 秒，提升效率約 45%，同時維持相近的準確率 84.79%，以顯示區塊循環結構在 LSTM 架構中兼顧效能與解釋力。

而在 GRU 的架構下，PSO-BLKGRU 僅需 297.87 秒即可完成訓練，雖然其準確率為 81.56%，略低於 LSTM 與傳統 GRU，但其 RMSE 僅 0.099，顯示在模型誤差的整體穩定性上仍具一定優勢。

表格 六 QPSO 演算法針對電力變壓器資料集之預測結果

	QPSO-BLKLSTM	QPSO-LSTM	QPSO-BLKGRU	QPSO-GRU
推薦參數	[4, 257, 128, 12, 0, 64]	[4, 257, 128, 12, 0, 64]	[3, 256, 128, 4, 1, 58]	[3, 256, 128, 4, 1, 58]
Training time	785.79 sec	1659.80 sec	709.12sec	1416.68 sec
Accuracy	88.41%	88.22%	83.94%	84.09%
MAPE	11.59%	11.78%	16.06%	15.91%
RMSE	0.4307	0.1036	0.1071	0.1154
MAE	0.0737	0.0725	0.0864	0.0871
R^2	0.9898	0.9336	0.9291	0.9176

由表格六可觀察在 LSTM 的比較中，QPSO-BLKLSTM 相較傳統 QPSO-LSTM，在訓練時間上明顯縮短約 52.7%，同時在準確率、MAPE、 R^2 等評估指標上略優。而在 GRU 架構下，QPSO-BLKGRU 在準確率與誤差的比較上略低於 QPSO-GRU，但其訓練效率顯著提升，訓練時間僅需 709.12 秒，相較於傳統 QPSO-GRU 的 1416.68 秒，縮短了近 50%。

	PSO- BLKLSTM	PSO-LSTM	PSO- BLKGRU	PSO-GRU	QPSO- BLKLSTM	QPSO-LSTM	QPSO- BLKGRU	QPSO-GRU
推薦參數	[6, 256, 128, 3, 0, 8]	[6, 256, 128, 3, 0, 8]	[5, 256, 128, 3, 1, 64]	[5, 256, 128, 3, 1, 64]	[4, 257, 128,12, 0, 64]	[4, 257, 128,12, 0, 64]	[3, 256, 128, 4, 1, 58]	[3, 256, 128, 4, 1, 58]
Training time	311.08 sec	569.44 sec	297.87 sec	506.45 sec	785.79 sec	1659.80 sec	709.12 sec	1416.68 sec
Accuracy	84.79%	85.55%	81.56%	82.08%	88.41%	88.22%	83.94%	84.09%
MAPE	15.21%	14.45%	18.44%	17.92%	11.59%	11.78%	16.06%	15.91%
RMSE	0.2193	0.0912	0.099	0.8058	0.4307	0.1036	0.1071	0.1154
MAE	0.0575	0.0686	0.7494	0.0559	0.0737	0.0725	0.0864	0.0871
R^2	0.9600	0.9485	0.9388	0.9598	0.9898	0.9336	0.9291	0.9176

圖 6 PSO 及 QPSO 演算法針對電力變壓器資料集之預測結果綜合比較

在電力變壓器的大規模資料集下，LSTM、BLKLSTM 等模型表現普遍優於 GRU；而區塊循環矩陣的結構能顯著降低訓練時間，而 QPSO 則能顯著提升精度。若要兼顧效能與精度，PSO-BLKLSTM 是一個折衷的選擇；若追求最高準確率，則 QPSO-BLKLSTM 及 QPSO-LSTM 最佳。

從實驗結果可觀察到，不同資料量對模型效能影響顯著。在電力變壓器大規模資料集下，LSTM、BLKLSTM 等模型，特別是 QPSO-BLKLSTM 與 QPSO-LSTM，皆展現最佳準確率與最低誤差其準確率約 88%，MAPE 約 11–12%，同時具有較高的 R^2 ，最高可達 0.9898，顯示在樣本數充足時，較複雜的 LSTM 結構能有效捕捉長期依賴關係，而 QPSO 的優化可以進一步提升泛化能力。然而其缺點在於訓練時間顯著增加，例如 QPSO-LSTM 需時超過 1600 秒。相

較之下，GRU 與 BLKGRU 訓練效率更高，例如：PSO-BLKGRU 僅約 298 秒，適合對運算成本敏感的應用情境。

在單車共享的小規模資料集下，模型整體表現明顯下降，準確率普遍僅落在 82–87% 間， R^2 最高僅 0.77，顯示小樣本不足以支撐複雜模型學習。雖然在此情況下，LSTM 仍略優於 GRU，但差距不大，且 QPSO 帶來的效益有限，甚至可能因過度調參導致效果不穩定。總體而言，大資料集建議採用 BLKLSTM + QPSO，以追求高精度；小資料集則宜選擇結構簡潔、訓練快速的 GRU 或 BLKGRU，以避免過擬合並提升效率。



中原大學

第5章、結論

本研究提出一套結合區塊循環結構與量子行為粒子群演算法的深度學習模型之架構。透過 QPSO 演算法對區塊循環遞迴神經網路進行超參數的探索，同時結合 MAPE(平均絕對百分比誤差)評估值做模型適配度指標。

而我們的實驗結果顯示了，在大資料集下，LSTM、BLKLSTM 等模型搭配 QPSO 能獲得最高精度與最佳泛化能力，例如：Accuracy 約 88%、 R^2 最高 0.9898，而 BLK 結構則能在維持良好效能的同時大幅縮短訓練時間。相對地，在小資料集下，整體表現明顯下降，例如： R^2 最高僅約 0.77，LSTM 雖仍略優於 GRU，但差距不大，且 QPSO 提升的精度有限。總體而言，大樣本建議採用 QPSO-LSTM 或 QPSO-BLKLSTM，以追求高精度；小樣本則宜選擇結構簡潔、訓練快速的 GRU 或 BLKGRU，以兼顧效率與穩定性。

綜觀以上的結果，本研究所提出之架構，在預測準確度、訓練效率與穩定性三個方面皆展現出優於傳統模型的整體效能，證實 QPSO 演算法結合區塊循環遞迴神經網路的設計，能有效提升模型表現並兼顧運算成本，具備高度實務應用潛力，是一個可行且極具潛力的深度學習模型之架構。

參考文獻

- [1] Z. Li, C. Ding, J. Xie, H. Zhang, B. Yuan, Y. Wang, and Y. Liang, “E-RNN: Design optimization for efficient recurrent neural networks in FPGAs,” in *Proc. IEEE Int. Symp. High Performance Computer Architecture (HPCA)*, Washington, DC, USA, 2019, pp. 69–80, doi: 10.1109/HPCA.2019.00028.
- [2] N. Challapalle, S. Venkataramani, A. Raghunathan, and K. Roy, “PSB-RNN: A processing-in-memory systolic array architecture using block circulant matrices for recurrent neural networks,” in *Proc. Design, Automation & Test in Europe Conf. & Exhibition (DATE)*, Grenoble, France, 2020, pp. 180–185, doi: 10.23919/DATE48585.2020.9116469.
- [3] J. Kennedy and R. Eberhart, “Particle swarm optimization,” in *Proc. Int. Conf. Neural Networks (ICNN)*, Perth, WA, Australia, 1995, vol. 4, pp. 1942–1948, doi: 10.1109/ICNN.1995.488968.
- [4] Y. Xu, C. Hu, Q. Wu, S. Jian, Z. Li, Y. Chen, G. Zhang, Z. Zhang, and S. Wang, “Research on particle swarm optimization in LSTM neural networks for rainfall-runoff simulation,” *J. Hydrology*, vol. 608, p. 127553, 2022, doi: 10.1016/j.jhydrol.2022.127553.
- [5] Y. Zhang, P. Zhang, W. Zhang, and M. Wang, “CNN-LSTM-attention with PSO optimization for temperature and fault prediction in meat grinder motors,” *Discover Appl. Sci.*, vol. 7, 2025, doi: 10.1007/s42452-025-07011-3.
- [6] J. Sun, B. Feng, and W. Xu, “Particle swarm optimization with particles having quantum behavior,” in *Proc. Congress on Evolutionary Computation (CEC)*, Portland, OR, USA, 2004, vol. 1, pp. 325–331, doi: 10.1109/CEC.2004.1330875.
- [7] M. Al-Behadili, D. Ouelhadj, and D. Jones, “Multi-objective particle swarm optimisation for robust dynamic scheduling in a permutation flow shop,” in *Advances in Intelligent Systems and Computing*, vol. 557, Springer, 2017, pp. 498–507, doi: 10.1007/978-3-319-53480-0_49.

- [8] H. Garg, “A hybrid PSO-GA algorithm for constrained optimization problems,” *Appl. Math. Comput.*, vol. 274, pp. 292–305, 2016, doi: 10.1016/j.amc.2015.11.001.
- [9] K. Brezinski and K. Ferens, “Cognitive hybrid PSO/SA combinatorial optimization,” in *Proc. IEEE 18th Int. Conf. Cognitive Informatics & Cognitive Computing (ICC/ICC)**, Milan, Italy, 2019, pp. 389–393, doi: 10.1109/ICC/ICC46617.2019.9146062.
- [10] M. Cao, Y. Liang, Y. Zhu, G. Lü, and Z. Ma, “Prediction for origin-destination distribution of dockless shared bicycles: A case study in Nanjing City,” *Front. Public Health*, vol. 10, p. 849766, 2022, doi: 10.3389/fpubh.2022.849766.
- [11] S. Liao, Z. Li, X. Lin, Q. Qiu, Y. Wang, and B. Yuan, “Energy-efficient, high-performance, highly-compressed deep neural network design using block-circulant matrices,” in *Proc. IEEE/ACM Int. Conf. Computer-Aided Design (ICCAD)*, Irvine, CA, USA, 2017, pp. 458–465, doi: 10.1109/ICCAD.2017.8203813.
- [12] S. Wang, Z. Li, C. Ding, B. Yuan, Q. Qiu, Y. Wang, and Y. Liang, “C-LSTM: Enabling efficient LSTM using structured compression techniques on FPGAs,” in *Proc. ACM/SIGDA Int. Symp. Field-Programmable Gate Arrays (FPGA)*, 2018, pp. 11–20, doi: 10.1145/3174243.3174253.
- [13] C. Ding, S. Liao, Y. Wang, Z. Li, N. Liu, Y. Zhuo, C. Wang, X. Qian, Y. Bai, G. Yuan, X. Ma, Y. Zhang, J. Tang, Q. Qiu, X. Lin, and B. Yuan, “CirCNN: Accelerating and compressing deep neural networks using block-circulant weight matrices,” *arXiv preprint arXiv:1708.08917*, 2017.
- [14] M. A. Alhartomi, A. A. A. El-Moursy, A. G. Radwan, and A. M. Eltawil, “Low-area and low-power VLSI architectures for long short-term memory networks,” *IEEE J. Emerg. Sel. Topics Circuits Syst.*, vol. 13, no. 4, pp. 1000–1014, Dec. 2023, doi: 10.1109/JETCAS.2023.3330428.
- [15] T. Gong and Y. Ma, “PSO-based lightweight neural architecture search for object detection,” *Swarm Evol. Comput.*, vol. 90, p. 101684, 2024, doi:

10.1016/j.swevo.2024.101684.

[16] D. Wang, L. Zhai, J. Fang, Y. Li, and Z.-J. Xu, “psoResNet: An improved PSO-based residual network search algorithm,” *Neural Netw.*, vol. 172, p. 106104, 2024, doi: 10.1016/j.neunet.2024.106104.

[17] F. Pedroza-Castro, A. Rojas-Dominguez, and M. Carpio, “Automated machine learning to improve stock-market forecasting using PSO and LSTM networks,” in *Proc. Int. Conf. Applied Computing and Information Technology (ACIT)*, 2023, pp. xxx–xxx, doi: 10.1007/978-3-031-28999-6_21.

[18] F. Deng, Y. Liu, Z. Wang, J. Chen, and L. Huang, “QPSO-LSTM based electricity sales forecasting model,” in *Proc. Asia Energy and Electrical Engineering Symp. (AEEES)*, Chengdu, China, 2024, pp. 1347–1352, doi: 10.1109/AEEES61147.2024.10544443.

[19] W. Li, “Load forecasting method based on QPSO-LSTM,” *Appl. Comput. Eng.*, vol. 142, pp. 18–22, 2025, doi: 10.54254/2755-2721/2025.KL21491.

[20] S. Khan, T. Mazhar, T. Shahzad, T. Ali, M. Ayaz, Y. Ghadi, E.-H. Aggoune, and H. Hamam, “Optimizing load demand forecasting in educational buildings using quantum-inspired particle swarm optimization (QPSO) with recurrent neural networks (RNNs): A seasonal approach,” *Sci. Rep.*, vol. 15, p. 19349, 2025, doi: 10.1038/s41598-025-04301-z.

[21] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, and W. Zhang, “Informer: Beyond efficient transformer for long sequence time-series forecasting,” *arXiv preprint arXiv:2012.07436*, 2020